


Этакое большое ничего и матстат

Белкин Дмитрий, U-1152
Бертыш Вадим, СПБГЭТУ «ЛЭТИ» 4373

15 июня 2016



U-1152

Основные определения

Определение 1 (Статистический эксперимент). *Тройка $(\mathfrak{X}, \mathfrak{F}, \mathcal{P})$ называется статистическим экспериментом*

- \mathfrak{X} - Множество результатов эксперимента
- \mathfrak{F} - Совокупность наблюдаемых событий
- $\mathcal{P} = \{P_\theta, \theta \in \Theta\}$ - Семейство вероятностных распределений

Дальше положим $\mathfrak{X} = \mathbb{R}^n$, $\mathfrak{F} = \sigma(\mathfrak{F}_1 \times \cdots \times \mathfrak{F}_n) = \mathfrak{B}_n$

Определение 2 (Статистика). *Измеримая функция $T : \mathfrak{X} \rightarrow E$ называется статистикой*

Определение 3 (Подчиненная статистика). *Статистика T называется подчиненной, если её распределение не зависит от параметра*

$$P_\theta(T \in A) = P_T(A)$$

Определение 4 (Достаточная статистика). *Статистика T называется достаточной, если условное распределение X при условии T не зависит от параметра*

$$P_\theta(X \in A|T) = P_{X|T}(A), \forall \theta \in \Theta$$

Подчиненная не содержит информации о параметре, достаточная содержит всю информацию о параметре

Определение 5 (Минимальная достаточная статистика). *Достаточная статистика T называется минимальной, если, $\forall T_1$ достаточной $\exists g : T = g(T_1)$*

Использование МДС максимально редуцирует имеющиеся данные

Основные типы задач статистики

- Точечное оценивание (статистики $\delta : \mathfrak{X} \rightarrow \Theta$)
- Доверительное оценивание с уровнем доверия $1 - \alpha$ (\mathcal{Y} - семейство подмножеств Θ)

$$\Delta : \mathfrak{X} \rightarrow \mathcal{Y}$$

такие, что $P_\theta(\theta \in \Delta(\vec{X})) \geq 1 - \alpha, \forall \theta \in \Theta$

- Проверка гипотез (принятие решений)
 $H : \theta \in \Theta_*, \Theta_* \subset \Theta$ - Гипотеза. Выдвигают $H_0 : \theta \in \Theta_0$ и $H_A : \theta \in \Theta$
Решающее правило - критерий

$$\phi : \mathfrak{X} \rightarrow [0; 1]$$

$\phi(\vec{X})$ - вероятность выбрать альтернативу (отвергнуть H_0)

Асимптотический подход Пусть $(\mathfrak{X}^{(n)}, \mathfrak{F}^{(n)}, \mathcal{P}^{(n)})$ последовательность статистических экспериментов $\mathcal{P}^{(n)} = \{p_\theta^{(n)}, \theta \in \Theta\}$

Определение 6 (Состоятельность оценки). Точечная оценка $\delta^{(n)}(\vec{X})$ называется состоятельной, если

$$\delta^{(n)}(\vec{X}) \xrightarrow{p_\theta} \theta, \forall \theta \in \Theta$$

Определение 7 (Сильная состоятельность оценки). Точечная оценка $\delta^{(n)}(\vec{X})$ называется сильно состоятельной, если

$$\delta^{(n)}(\vec{X}) \xrightarrow[n \rightarrow \infty]{p_\theta = 1} \theta, \forall \theta \in \Theta$$

Определение 8 (Асимптотическая нормальность). Точечная оценка $\delta^{(n)}(\vec{X})$ называется асимптотически нормальной, если

$$\sqrt{n}(\delta^{(n)}(\vec{X}) - \theta) \xRightarrow{P_\theta} \mathcal{N}(0, \sigma^2(\theta))$$

Методы накопления статистической информации

- Выборочный метод

Определение 9 (Выборка). набор НОРСВ $\vec{X} = (x_1, \dots, x_n)$ называется выборкой

Совместное распределение задается распределением x_1 , Θ не меняется с ростом n

- Группировка

Разбиваем наблюдения на k групп. Наблюдаемые величины: $(x_1, z_1), \dots, (x_n, z_n) \in \mathfrak{X}$, где x_i - наблюдаемое значение, а $z_i \in \{1, \dots, k\}$ - принадлежность его к какой-либо группе. Распределения в пределах группы совпадают. Совместное распределение определяется распределением при каждом $z_i - F_s, s = 1, \dots, k$

- Регрессия

Определение 10 (Регрессия). Регрессией величины Y по X называют $E[Y|X] = f(x)$

Модель основана на соотношении

$$E_\theta[Y, X(z)] = g_\theta(X(z)^T)$$

Распределение Y характеризуется F_z

Параметризация

$$\mathcal{P} = \{p_\theta, \theta \in \Theta\}$$

По типу множества Θ можно выделить

- Параметрические $\Theta \subset \mathbb{R}^d$
- Семипараметрическими $\Theta \subset \Theta_1 \times \Theta_2, \Theta_1 \subset \mathbb{R}^d$
- Непараметрические (остальные)

Непараметрическое оценивание (Выборочный подход) Пусть X_1, \dots, X_n - выборка из распределения $P_\theta, \theta \in \Theta$, истинное значение P_θ будем называть *теоретическим распределением*.

Определение 11 (Выборочная функция распределения). *Выборочной функцией распределения называют*

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{\{X_i \leq x\}} = \frac{\text{Число наблюдений меньших } x}{\text{общее число наблюдений}}$$

Теорема 1 (Гливленко-Кантелли).

$$\sup_x \{|F_n(x) - F(x)|\} \xrightarrow[n \rightarrow \infty]{P_\theta=1} 0, \forall F$$

Утверждает сильную состоятельность F_n

Теорема 2 (Колмогорова).

$$\sqrt{n} \sup_x \{F_n(x) - F(x)\} \Rightarrow \mathcal{K}$$

Где \mathcal{K} - распределение Колмогорова, функция распределения $\mathcal{K}(x) = \sum_{j=-\infty}^{\infty} (-1)^j e^{-2j^2 x^2}$. Даёт возможность строить доверительные области для функции распределения. Пусть α - малое число, x_α - квантиль уровня $1 - \alpha$, тогда

$$1 - \alpha \approx P_F(\sqrt{n} \sup_x |F_n(x) - F(x)| < \alpha) = P_F(F_n(x) - \frac{x_\alpha}{\sqrt{n}} \leq F(x) \leq F_n(x) + \frac{x_\alpha}{\sqrt{n}})$$

Идея доказательства - преобразование Смирнова

Определение 12 (Преобразование Смирнова). *x с непрерывной функцией распределения F , $Y = F(x)$, тогда*

$$Y \sim \mathcal{U}(0, 1)$$

Определение 13 (Порядковые статистики, вариационный ряд и ранги). *Достаточная статистика*

$$X_{(1)} \leq X_{(2)} \leq \dots X_{(n)}$$

называется *вариационным рядом*, $X_{(k)}$ - k -ая *порядковая статистика*. Ранг R_k - номер x_k в вариационном ряду

Выборочные характеристики

Определение 14 (Выборочные характеристики). Пусть \mathcal{F} - подмножество множества распределений $\alpha : \mathcal{F} \rightarrow \mathbb{R}$ - *числовая характеристика*. Тогда

$\alpha(F)$ - *теоретическая характеристика*

$\alpha(F_n)$ - *выборочная характеристика*

Числовые характеристики можно разделить на две вида:

- Характеристики $H(Eg_1(X), \dots, Eg_n(X))$
- Непрерывный в равномерной метрике функционал $G(F)$

К первым относятся моментные характеристики, ко вторым квантили.

Теорема 3. Пусть X_1, \dots, X_n - Выборка из распределения с функцией распределения F , числовая характеристика $G(F)$ первого или второго типа существует, тогда с вероятностью 1

$$G(F_n) \xrightarrow{n \rightarrow \infty} G(F)$$

Выборочные квантили

Определение 15. ξ_p - квантиль порядка p , $\xi_p = x_{([np]+1)}$, если $np \in \mathbb{Z}$

Параметрическое оценивание

Определение 16 (Точечная оценка). Статистика $\delta(\vec{X})$, $\delta: \mathfrak{X} \rightarrow \Theta$ называется точечной оценкой

Определение 17 (Функция потерь). пусть θ реально значение параметра, тогда $W(\delta(\vec{X}), \theta)$ функция потерь, если

- $W(\delta(\vec{X}), \theta) > 0, \forall \vec{X} \in \mathfrak{X}$
- $W(\theta, \theta) = 0$

Используют различные функции потерь (в дальнейшем используем функцию Гаусса)

$$W(\delta, \theta) = |\delta - \theta| \quad (\text{Лаплас})$$

$$W(\delta, \theta) = (\delta - \theta)^2 \quad (\text{Гаусс})$$

Определение 18 (Риск). Риском называют $R(\delta, \theta) = E_\theta[W(\delta(\vec{X}), \theta)]$